基于位置注意力增强的 Swin Transformer 街景字符识别

目录

1.问题描述 2

1.1 赛题背景与目标 2

1.2 数据说明 2

2.数据分析 2

2.1 数据分析 2

2.1 数据预处理 4

2.1.1 数据增强 4

2.1.2 数据集加载与标签处理 4

2.2 数据采样和划分 4

3.特征工程 4

3.1 特征提取 5

3.2 特征提取 5

3.3 特征选择与转换 5

4.模型建立与优化 6

4.1 建立模型 6

4.2 模型优化 7

5.模型评估 8

5.1 评估指标 8

5.2 评估流程 8

5.3 评估结果 9

1.问题描述

1.1 赛题背景与目标

本赛题聚焦计算机视觉领域的字符识别任务，要求对给定的街道字符图片进行识别，预测图片中包含的所有字符编码。每张图片可能包含 1 个或多个字符，识别需覆盖全部字符，任何一个字符识别错误即判定为整体错误。

1.2 数据说明

数据由训练集，验证集，测试集构成，其中训练集有 3 万张图片，验证集有 1 万张图片，训练集和验证集包含字符编码标签及字符位置框信息，测试集有 4 万张图片，无标签信息。

数据标签包含字符的位置信息（top 左上角 X 坐标、left 左上角 Y 坐标、height 高度、width 宽度）和字符编码（label），标签格式为 JSON 文件，需通过指定方式读取（如提供的 parse_json 函数）。

2.数据分析

2.1 数据分析

数据由训练集，验证集，测试集构成，其中训练集有 3 万张图片，验证集有 1 万张图片，测试集有 4 万张图片。统计训练集图片中字符个数的分布得知 1 位字符有 4,636 张，2 位字符有 16262，3 位字符有 7813，4 位字符有 1280，5 位字符有 8 张，而 6 位字符只有 1 张，可知大部分的图像中字符个数为 2-4 个，最多的字符个数为 6 个。根据图片尺寸和字符尺寸分析，如图 1 所示，图片的宽度主要集中在 100 到 600 之间，高度主要集中在 20 到 150 之间，大部分图片的宽高比在 3:1 到 4:1 之间；如图 2 所示，标注框的宽度和高度分布比较集中，宽度大部分在 20 到 100 之间，高度在 20 到 40 之间。大部分标注框的宽高比是在 1:1 到 5:1 之间。数据分析图如下

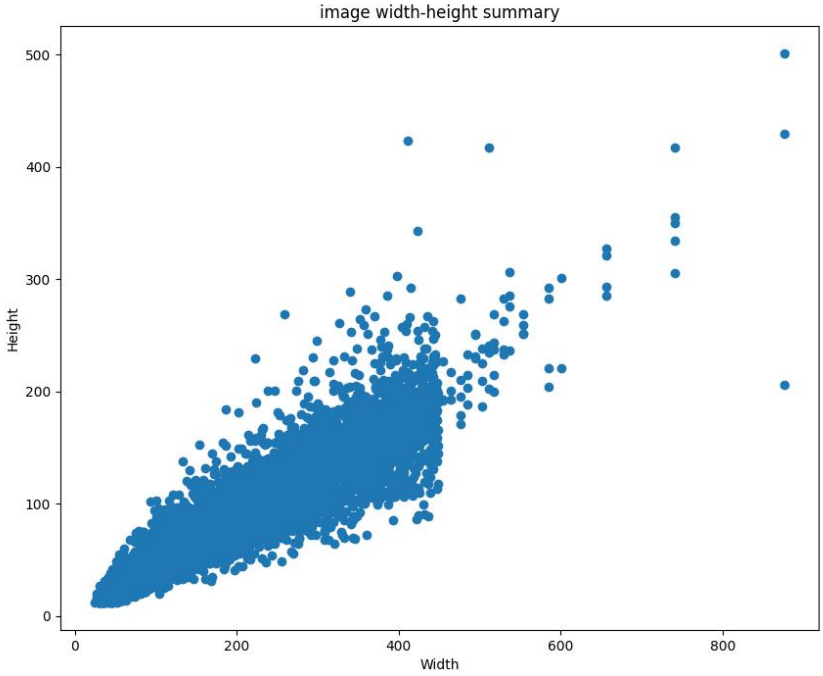


图 1 图片尺寸统计

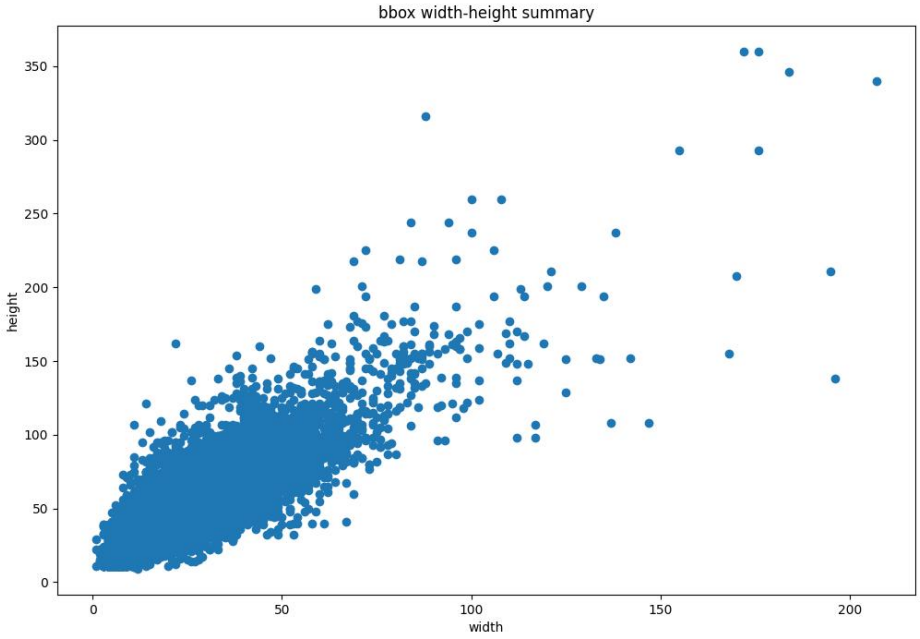


图 2 标注框的尺寸统计

2.1 数据预处理

数据预处理主要分为数据增强和数据集加载与标签处理两部分。

2.1.1 数据增强

针对训练集和验证集设计不同变换策略来提升模型泛化能力。训练集增强包括：统一图片尺寸为 224*224；随机调整亮度、对比度、饱和度和色调；以 20% 概率转为灰度图；随机旋转、平移、缩放和剪切；以 50% 概率水平翻转；随机高斯模糊；转为张量并归一化值到 0 - 1；以 30% 概率随机擦除部分区域；用 ImageNet 的均值和标准差归一化加速模型收敛。验证集/测试集变换仅包含统一图片尺寸、转为张量并归一化值到 0 - 1、用 ImageNet 的均值和标准差归一化加速模型收敛，无随机增强，确保验证和测试时数据稳定。

2.1.2 数据集加载与标签处理

数据加载方面，训练集和验证集加载图片路径并关联 JSON 标签，测试集仅加载图片路径无标签。标签处理是将不定长字符转为定长 6 个字符，因为数据中字符数最多为 6，截取标签中前 6 个字符，剩余位置用 10 填充（10 代表空字符），例如原标签为[2,3]，处理后为[2,3,10,10,10,10]；原标签为[2,3,1]，处理后为[2,3,1,10,10,10]。模式适配根据 mode（train/val/test）和 aug（是否增强）自动选择对应的变换策略，训练集用增强变换，验证集和测试集用基础变换。

2.2 数据采样和划分

采用分层 K 折交叉验证，基于每张图片的字符数量进行分层抽样，确保每个折中字符数量的分布与整体一致，提升模型评估的稳定性。同时进行加权采样处理类别不平衡问题，对字符数量较少的样本赋予更高权重，通过 class_weights 计算（$w_i = \frac{1}{\text{class_count}_i}$），缓解数据中字符数量分布不均的问题。

3.特征工程

在本赛题中，我们的特征工程主要围绕了特征提取、特征增强、特征选择与转换展开，结合深度学习模型的自动特征学习能力与手工设计的特征处理策略，

以提升模型对字符的识别效果。

3.1 特征提取

我们采用的是 Swin Transformer 作为特征提取的核心骨干网络，实现从原始图像到高级语义特征的自动转换，这是深度学习中特征工程的核心环节。Swin Transformer 具有独特的特征提取机制，通过“分块（Patch Partition）→ 窗口自注意力（Window Self-Attention）→ 跨窗口连接（Shifted Window）”的分层结构，逐步将原始像素信息（224x224x3）转换为高级特征向量。输入图像经分块后转为序列，每个 Patch 为 4x4 像素，224x224 图像可生成 56x56＝3136 个 Patch；再通过多层自注意力机制捕捉 Patch 间的空间关系和语义关联，最终输出维度为 num_features（Swin-Base 模型为 1024）的特征向量，该向量融合了图像的局部细节和全局上下文信息。相比传统手工设计特征（如 HOG、SIFT），Swin Transformer 能自动学习更具判别力的特征，可适应字符的形变、光照变化等复杂场景。

3.2 特征提取

为了解决单张图像中多字符位置存在差异的问题，我们设计了位置注意力模块，对骨干网络输出的特征进行加权增强，突出不同字符位置的关键特征。在 SwinTransformerModel 类中，定义了 6 并行的注意力模块（attn1 至 attn6），分别对应 6 个可能的字符位置，因为我们在数据预处理中将字符统一为 6 个位置。每个注意力模块为一个小型 MLP（多层感知机），具体结构为： Linear(1024→1024)→ReLU→Dropout→Linear(1024→512)→ReLU→Dropout→Linear(512→1)→Sigmoid；模块输出为 0 - 1 之间的注意力权重（a1 至 a6），表示骨干网络特征中对该位置字符识别的重要性；通过权重与骨干特征相乘（feat1 = features * a1），可增强关键特征、抑制无关信息。该机制使模型能自适应关注图像中不同字符的位置区域，从而提升特征对位置敏感性。

3.3 特征选择与转换

在得到位置加权特征后，我们通过分类器模块对特征进行进一步的转换，使其更适合字符分类任务。分类器中每个字符位置对应一个分类器（fc1 至 fc6），

包含以下特征转换操作：Linear(feat_dim→512)将高维特征（1024 维）降维至 512 维，减少冗余；BatchNorm1d(512)对特征进行归一化，加速模型收敛，增强特征稳定性；ReLU 引入非线性变换，增强模型对非线性特征的表达能力；Dropout(config.dropout_rate)随机丢弃部分特征（dropout 率 50%），防止过拟合，提升特征的泛化能力；Linear(512→class_num)将特征映射到 11 个类别（0 - 9 数字 + 空字符），完成特征到类别概率的转换。

4.模型建立与优化

在本赛题中，模型的建立与优化是通过模型架构设计、损失函数优化、超参数配置、验证策略及训练过程调控等多环节协同实现，旨在构建适配字符识别任务的高性能模型。

4.1 建立模型

建模主要聚焦于构建适配字符识别任务的网络结构，融合特征提取、注意力机制与分类头。

首先我们选用的是 Swin Transformer 作为特征提取骨干。其分层 Transformer 结构，借助“窗口自注意力”和“跨窗口连接”，能捕捉图像局部细节与全局上下文，适合字符小目标特征学习。输入尺寸 224x224 与预训练模型一致，便于利用预训练权重加速收敛。

然后针对单张图像含多个字符的情况，在骨干网络后添加 6 个并行位置注意力模块（attn1 – attn6），对应 6 个字符位置。每个模块为小型 MLP，输出 0 - 1 权重值，通过“特征×注意力权重”增强对应位置字符特征信号，抑制无关干扰，提升多字符识别准确性。

接着是分类头设计。模型输出层为 6 个并行分类器（fc1 – fc6），分别预测 6 个字符位置类别（0 - 9 数字 + 空字符，共 11 类）。每个分类器含“Linear 降维→BatchNorm→ReLU→Dropout→Linear 输出”结构，其中 BatchNorm 加速收敛、稳定特征分布，Dropout 防止过拟合，最终输出 11 维向量对应各类别预测概率。

为了解决字符识别中空字符样本少、易混淆字符难区分等问题，我们设计了

损失函数来融合多种损失机制。使用 Focal Loss 降低易分类样本权重，聚焦难样本（$(1-pt)^{\gamma}\ \ (\gamma=2)$）；标签平滑将真实标签从“one - hot”软化（平滑系数 0.1），避免模型过度自信，提升泛化性；类别权重为空字符（标签 10）赋予更高权重（2.0），缓解样本少导致的学习不足。

最后是优化器与学习率调度。优化器选用 AdamW，带权重衰减（weight_decay = 1e - 4），减少过拟合风险，稳定更新参数；学习率调度采用 CosineAnnealingLR，学习率随训练步数从初始值的 5e - 5 余弦衰减至最小值 1e - 6，实现前期快速收敛、后期精细调优。

4.2 模型优化

我们主要通过“超参数预设、交叉验证、早停、正则化”等手段优化模型性能。

首先是超参数的集中配置。我们将所有关键超参数集中在 Config 类中统一调整管理，所设参数：

超参数	取值	调参逻辑
batch_size	32	平衡 GPU 内存（224x224 图像下，32 batch 适合单卡训练）与训练稳定性
lr	5e-5	初始学习率
Epochs	30	训练周期，配合早停策略防止过拟合
img_size	224	匹配 Swin Transformer 预训练输入尺寸
dropout_rate	0.5	dropout 率
num_folds	5	5 折交叉验证
early_stopping_patience	7	若 7 个 epoch 验证准确率无提升则早停，避免无效训练
label_smoothing	0.1	轻微平滑标签，提升模型对相似字符的泛化性

交叉验证中我们采用分层 5 折交叉验证，基于每张图像的字符数量分层，确保各折字符数量分布一致。训练时每折使用不同训练/验证集划分，避免评估误

差，选取各折最佳模型集成提升泛化能力，验证超参数合理性。

在训练过程中采样早停策略和正则化，若连续 7 个 epoch 验证准确率未超过当前最佳值则停止训练；正则化手段包括 Dropout、权重衰减以及数据增强（如随机旋转、颜色抖动），防止特征过拟合，迫使模型学习更鲁棒特征。

最后在训练结束后，按验证准确率选取各折最佳模进行集成预测。对测试集图像，每个模型输出预测结果，结合测试时数据增强（TTA，3 次增强）提升稳定性，通过“投票法”融合多次增强的结果，降低单次随机性，优化预测性能。

5.模型评估

5.1 评估指标

在本题中，我们使用了三种评估指标，分别是损失值（Loss），样本准确率（Accuracy）和字符集准确率(Digit Accuracy)。

损失值用结合了 Focal Loss 和 Label Smoothing 的 EnhancedLoss 来计算，并且会对四个位置的损失取平均值，以此作为总损失。

样本准确率用于衡量整个数字代码预测正确的样本比例，只有当四个位置的数字全部预测正确时，才会判定该样本预测正确，公式如下：

$$Acc = \frac{\text{正确样本数}}{\text{总样本数}}$$

字符级准确率着重衡量每个位置上数字预测正确的比例，通过统计所有位置的正确预测数，再除以总位置数来计算，公式如下：

$$Digit\ Acc\ = \frac{\text{正确字符数}}{\text{总字符数}}$$

5.2 评估流程

在评估流程中，首先进入准备阶段，需要将模型设置为评估模式，以此禁用 Dropout 和 BatchNorm 在训练时的特定行为，同时采用 with t.no_grad()来禁用梯度计算，进而减少内存占用和计算开销。接着进入前向传播环节，要遍历验证数据加载器 val_loader，针对每个批次的图像开展前向传播操作，从而获取六个位

置的预测结果。随后进行损失计算，对每个位置的预测结果运用 EnhancedLoss 来计算损失，并将六个位置的损失取平均值，以此作为该批次的损失。之后是准确率计算，在样本级别上，要检查每个样本的六个位置是否全部预测正确；在字符级别上，需统计每个位置的正确预测数，然后进行累加并计算其比例。最后是结果汇总，要把所有批次的损失、正确样本数和正确字符数进行累加，分别计算出平均损失、样本准确率和字符级准确率，并将这三个指标返回，用于对模型进行评估。

5.3 评估结果

在最后一次的训练中验证集的平均损失值为 0.6146，样本准确率为 95.27%，字符级准确率为 98.56%，如图 3。从评估指标来看，模型性能非常优秀。样本准确率超过 95%，意味着在 100 个车牌中只有不到 5 个识别错误。字符级准确率接近 99%，说明模型在单个字符识别上几乎达到了人类水平。

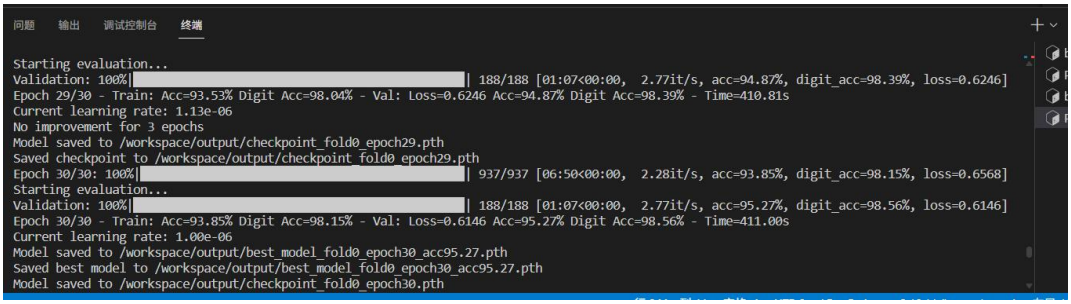


图 3 模型评估结果

最后测试集的前 5 个预测结果如图 4，根据人为判断，这个预测结果是比较好的



图 4 预测集前 5 个预测结果